

行動科学演習・数理行動科学研究演習 『社会科学のためのベイズ統計モデリング』第7章

Hiroshi Hamada
Tohoku University

Jun, 2020
at Tohoku University

確率モデルの情報量

例：ブログへのアクセス

確率モデルはポアソン分布

$$\text{Poisson}(x|\lambda) = \frac{\lambda^x}{x!} e^{-\lambda} \quad \lambda \text{は平均パラメータ}$$

予測分布を $\text{Poisson}(x|\lambda = 3)$ とおく

情報量

サンプルの実現値が x であるときの情報量

$$\begin{aligned} I(X = x) &= -\log p(X = x) = -\log \left(\frac{\lambda^x}{x!} e^{-\lambda} \right) \\ &= -x \log \lambda + \log x! + \lambda \end{aligned}$$

$\lambda = 3$ の場合, $x = 3$ の情報量は

$$-3 \log 3 + \log 3! + 3 \approx 1.49$$

$\lambda = 10$ の場合, $x = 3$ の情報量は

$$-3 \log 10 + \log 3! + 10 \approx 4.88$$

情報量は, データに近いモデルのほうが小さい

自由エネルギーの具体例

パラメータがガンマ分布に従うと仮定

$$X \sim \text{Poisson}(\lambda)$$

$$\lambda \sim \text{Gamma}(a, b)$$

周辺尤度（共役事前分布の恩恵）

$$p(x^n) = \frac{\Gamma(\sum x_i + a)}{\Gamma(a) \prod x_i!} \frac{b^a}{(n + b)^{\sum x_i + 1}}$$

自由エネルギーは周辺尤度を対数化して符号を反転した値

$$\begin{aligned} F_n &= -\log p(X^n = x^n) \\ &= -\log \left(\frac{\Gamma(\sum x_i + a)}{\Gamma(a) \prod x_i!} \frac{b^a}{(n+b)^{\sum x_i + 1}} \right) \\ &= -\log \Gamma \left(\sum x_i + a \right) + \log \Gamma(a) + \sum \log x_i! \\ &\quad - a \log b + \left(\sum x_i + a \right) \log(n+b) \end{aligned}$$

サンプルの実現値 $(3, 4, 2, 7, 8)$

$\lambda = 3$ のポアソン分布の自由エネルギーは,

$$F_{M_0} = 13.43$$

$a = 3, b = 1$ のガンマ分布を λ の事前分布とするポアソン分布の自由エネルギーは

$$F_{M_1} = 12.60$$

ただしベイズファクターによると決定的な差ではない

モデル評価とオーバーフィッティング

$$M_0 : X \sim \text{Poisson}(3)$$

$$M_1 : X \sim \text{Poisson}(\lambda), \lambda \sim \text{Gamma}(3, 1)$$




Figure: $\text{Poisson}(\lambda^* = 3)$ が真の分布. M_0 と M_1 の自由エネルギーの分布の比較




Figure: $\text{Poisson}(\lambda^* = 6)$ が真の分布. M_0 と M_1 の自由エネルギーの分布の比較

自由エネルギーの推定値の計算

確率モデル:ポアソン分布, 事前分布:ガンマ分布
逆温度 β の事後分布

$$\begin{aligned} p(\lambda|x^n)_\beta &= \frac{(n\beta + b)^{\sum x_i\beta + a}}{\Gamma(\sum x_i\beta + a)} \lambda^{\sum x_i\beta + a - 1} e^{-\lambda(n\beta + b)} \\ &= \frac{b_n^{a_n}}{\Gamma(a_n)} \lambda^{a_n - 1} e^{-b_n \lambda} \end{aligned}$$

$a_n = \sum x_i\beta + a, b_n = n\beta + b$ であるガンマ分布

WBIC の計算

$$\text{WBIC} = \mathbb{E}_{p(\lambda|x^n)_\beta} [nL_n(\lambda)]$$

対数経験損失の事後分布による期待値

近似計算

$$\text{WBIC}_{\text{mcmc}} = \frac{1}{S} \sum_{s=1}^S \left(\sum_{i=1}^n -\log p(x_i|\theta_s) \right)$$

自由エネルギーのシミュレーション




Figure: シミュレーション結果（実線が自由エネルギー，破線は各推定法による自由エネルギーの推定）

ブリッジ・サンプリング

周辺尤度の近似計算

- ナイーブ・モンテカルロ法

$$\hat{\theta}_i \sim \varphi(\theta), \quad \hat{p}_{NM}(x^n) = \frac{1}{R} \sum_{i=1}^R p(x^n | \hat{\theta}_i)$$

- 重点サンプリング法

$$\hat{\theta}_i \sim g(\theta), \quad \hat{p}_{IS}(x^n) = \frac{1}{R} \sum_{i=1}^R \left(p(x^n | \hat{\theta}_i) \frac{\varphi(\hat{\theta}_i)}{g(\hat{\theta}_i)} \right)$$

- 一般化調和平均サンプリング法

$$\hat{\theta}_j^* \sim p(\theta|x^n), \hat{p}_{GHM}(x^n) = \left(\frac{1}{R} \sum_{j=1}^R \left(\frac{1}{p(x^n|\theta_j^*)} \frac{g(\theta_j^*)}{\varphi(\theta_j^*)} \right) \right)$$

- ブリッジ・サンプリング法
MCMC サンプルから計算可能

```
1 target += (1/log(N))*poisson_lpmf(X | lambda);
```

逆温度を指定

汎化損失の推定

事後分布（事前分布はガンマ分布）

$$p(\lambda|x^n) = \frac{b_n^{a_n}}{\Gamma(a_n)} \lambda^{a_n-1} e^{-b_n \lambda}$$

$$a_n = \sum x_i + a, b_n = n + b.$$

予測分布

$$\begin{aligned} p^*(x) &= \int_0^\infty \underbrace{p(x|\lambda)}_{\text{確率モデル}} \underbrace{p(\lambda|x^n)}_{\text{事後分布}} d\lambda \\ &= \frac{\Gamma(x + a_n)}{\Gamma(a_n)x!} \frac{b_n^{a_n}}{(1 + b_n)^{x+a_n}}. \end{aligned}$$

真の分布が既知なので計算可能

$$\begin{aligned} G_n &= \int -\log p^*(x)q(x)dx && \text{定義より} \\ &= \sum_{i=0}^{\infty} -\log p^*(x_i)\text{Poisson}(x_i|\lambda^*) && \text{ポアソン分布を代入} \\ &= \sum_{i=0}^{\infty} \frac{1}{x_i!}(\lambda^*)^{x_i}e^{-\lambda^*}[-\log \Gamma(x+a_n) + \log \Gamma(a_n) + \log x \\ &\quad - a_n \log b_n + (x+a_n) \log(1+b_n)] \end{aligned}$$

WAIC の計算

経験損失 T_n と汎関数分散 V_n の計算が困難な場合→
MCMC 利用

経験損失 T_n の MCMC による推定値

$$T_n \approx \frac{1}{n} \sum_{i=1}^n \left[-\log \left(\frac{1}{S} \sum_{s=1}^S p(x_i | \theta_s) \right) \right]$$

S は MCMC のサンプルの個数

汎関数分散 V_n の MCMC による推定値

$$V_n \approx \sum_{i=1}^n \left[\frac{1}{S-1} \sum_{s=1}^S \log p(x_i | \theta_s)^2 - \left(\frac{1}{S-1} \sum_{s=1}^S \log p(x_i | \theta_s) \right)^2 \right]$$

MCMC からの WAIC

$$\begin{aligned}\text{WAIC}_{\text{mcmc}} = & \frac{1}{n} \sum_{i=1}^n \left[-\log \left(\frac{1}{S} \sum_{s=1}^S p(x_i | \theta_s) \right) \right] \\ & + \frac{1}{n} \sum_{i=1}^n \left[\frac{1}{S-1} \sum_{s=1}^S \log p(x_i | \theta_s)^2 \right. \\ & \left. - \left(\frac{1}{S-1} \sum_{s=1}^S \log p(x_i | \theta_s) \right)^2 \right]\end{aligned}$$

Stan code

Stan 上で、以下の generated quantities ブロックを model ブロックの下にコピーして、データポイントごとに対数尤度を計算 (poisson_WAIC.stan として保存)

```
1 generated quantities{  
2   real log_lik[N];  
3   for(n in 1:N){  
4     log_lik[n] = poisson_lpmf(X[n] | lambda);  
5   }  
6 }
```

Stan code

Stan で生成した `log_lik` を `extract` 関数で取り出し、関数 `waic_mcmc` の引数として渡す

```
1 waic_mcmc <- function(log_lik){
2   T_n <- mean(-log(colMeans(exp(log_lik))))
3   V_n_divide_n <- mean(apply(log_lik,2,var))
4   waic <- T_n + V_n_divide_n
5   return(waic)
6 }
7
8 model.waic <- stan_model("poisson_WAIC.stan")
9 fit.waic <- sampling(model.waic, data=list(N=n,X=x,a=a
10   ,b=b))
11 log_lik <- rstan::extract(fit.waic)$log_lik
12 waic_mcmc(log_lik)
```

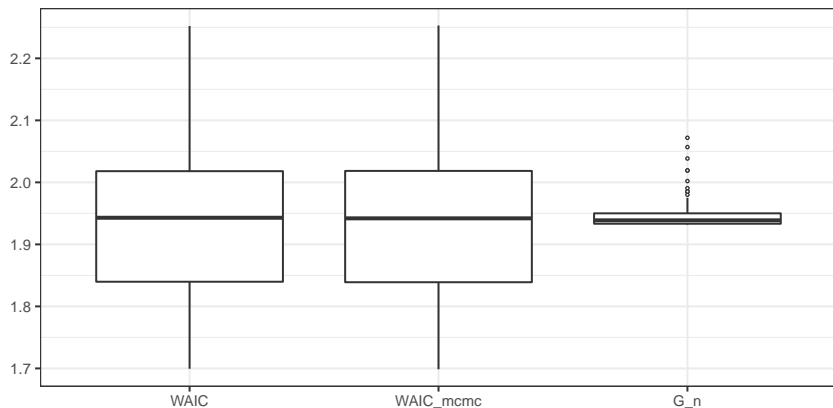


Figure: WAIC と汎化損失のシミュレーション結果

まとめ

- 自由エネルギーは複雑なモデルにペナルティが加わる
- ブリッジ・サンプリングによる推定は精度が良い
- モデルの良さの指標はサンプルの現れ方の変動の影響を受ける
- 解析的に分析できないモデルでも WAIC を MCMC サンプルから計算できる