

# 『社会科学のためのベイズ統計モデリング』第3章

Hiroshi Hamada  
Tohoku University

May, 2020  
at Tohoku University

## 3.1 同時分布と条件付き確率

同時確率分布：

2つの確率変数の組  $(X, Y)$ ，確率密度関数  $p(x, y)$

**周辺確率分布** (marginal probability distribution)：

$$p(x) = \int p(x, y) dy, \quad p(y) = \int p(x, y) dx$$

同時確率分布から片方の変数を積分消去して得た確率分布 (確率密度関数)

$X$  が与えられたときの  $Y$  の条件付き確率分布

$$p(y|x) = \frac{p(x, y)}{p(x)}$$

ベイズ推測にはパラメータ  $\theta$  が与えられたときの  $X$  の条件付き確率分布  $p(x|\theta)$  と  $\theta$  の確率分布  $\varphi(\theta)$  が必要

$p(x|\theta)$  : 確率モデル,       $\varphi(\theta)$  : 事前分布

## 3.2 事後分布

### 定義 (事後分布)

パラメータ  $\theta$  の**事後分布** (posterior distribution) を

$$p(\theta|x^n) = \frac{1}{Z_n} \prod_{i=1}^n p(x_i|\theta)\varphi(\theta), Z_n = \int_S \prod_{i=1}^n p(x_i|\theta)\varphi(\theta) d\theta$$

と定義する．積分の範囲  $S$  はパラメータ  $\theta$  のとりうる範囲 ( $\theta \in S$ )． $Z_n$  を**周辺尤度** (marginal likelihood) または**分配関数** (partition function) という．

事後分布の直感的意味：データを条件とする，パラメータの条件付き確率

周辺尤度  $Z_n$  は事後分布の正規化定数であり，かつ，サンプル（確率変数）

$$X^n = (X_1, X_2, \dots, X_n)$$

の確率密度関数．  $Z_n$  を  $(x_1, x_2, \dots, x_n)$  で積分すると

$$\begin{aligned} & \iint \cdots \int Z_n dx_1 dx_2 \cdots dx_n \\ &= \int_S \varphi(\theta) d\theta \prod_{i=1}^n \left( \int p(x_i | \theta) dx_i \right) = \int_S \varphi(\theta) d\theta \cdot 1 = 1 \end{aligned}$$

## 3.3 予測分布

### 定義 (予測分布)

事後分布により確率モデルを平均した

$$p^*(x) = \mathbb{E}_{p(\theta|X^n)}[p(x|\theta)] = \int p(x|\theta)p(\theta|X^n)d\theta$$

を**予測分布** (predictive distribution) という

ベイズ推測とは

「真の分布  $q(x)$  は、おおよそ予測分布  $p^*(x)$  であろう」  
と推測することをいう（渡辺 2012）.

## 3.4 ベイズ推測の具体例

データを生成する未知の分布をパラメータ  $q$  のベルヌーイ分布（仮の確率モデル）で推測する。

仮のモデルのもとで，データ  $y^n = (y_1, y_2, \dots, y_n)$  を観測する  $n$  人分の同時確率

$$p(y^n|q) = \prod_{i=1}^n q^{y_i} (1 - q)^{1-y_i}$$



# 事前分布

$q$  の事前分布として実現値が  $[0, 1]$  の区間に収まる分布  $\text{Beta}(a, b)$  を仮定する

$$q \sim \text{Beta}(a, b).$$

ベータ分布  $\text{Beta}(a, b)$  の確率密度関数  $\varphi(q)$  は

$$\varphi(q) = \frac{1}{\text{B}(a, b)} q^{a-1} (1 - q)^{b-1}$$

$\text{B}(a, b)$  はベータ関数と呼ばれる定数

$$\text{B}(a, b) = \int_0^1 x^{a-1} (1 - x)^{b-1} dx.$$

# 事後分布の計算

$$\begin{aligned}& \frac{1}{Z_n} \left( \prod_{i=1}^n q^{y_i} (1-q)^{1-y_i} \right) \varphi(q) \\&= \frac{1}{Z_n} \left( \prod_{i=1}^n q^{y_i} (1-q)^{1-y_i} \right) \underbrace{\frac{q^{a-1} (1-q)^{b-1}}{\mathrm{B}(a, b)}}_{\text{ベータ分布の確率密度関数}} \\&= \frac{1}{Z_n} \left( q^{\sum y_i} (1-q)^{n-\sum y_i} \right) \frac{q^{a-1} (1-q)^{b-1}}{\mathrm{B}(a, b)} \\&= \frac{1}{Z_n \cdot \mathrm{B}(a, b)} q^{\sum y_i + a - 1} (1-q)^{n - \sum y_i + b - 1}\end{aligned}$$

- 事後分布  $p(q|y^n)$  は、ベータ分布

$$\frac{q^{\sum y_i + a - 1} (1 - q)^{n - \sum y_i + b - 1}}{B(a + \sum y_i, b + n - \sum y_i)}$$

パラメータは  $a + \sum y_i, b + n - \sum y_i$

- 事前分布  $\varphi(\theta)$  と事後分布  $p(\theta|x^n)$  が同じ種類の確率分布になるよう設定した事前分布を**共役事前分布**という.
- 共役事前分布を設定した場合、事後分布は解析的に計算できる（できない場合→ MCMC）

# 事後分布の具体例

Table: 10 人分の保険加入記録データ (再掲)

個人	$y_1$	$y_2$	$y_3$	$y_4$	$y_5$	$y_6$	$y_7$	$y_8$	$y_9$	$y_{10}$
行動	0	1	0	0	0	0	1	0	0	0

これを使って最尤法 (2 章) ではなく, ベイズ推測する (3 章).

# 事後分布

$q$  の事後分布はサンプルの実現値  $y^n$  のもとで

$$\begin{aligned} & \text{Beta}(a + \sum y_i, b + n - \sum y_i) \\ &= \text{Beta}(1 + \sum y_i, 1 + n - \sum y_i) \\ &= \text{Beta}(1 + 2, 1 + 10 - 2) \\ &= \text{Beta}(3, 9) \end{aligned}$$

$q$  の事後確率分布であるベータ分布  $\text{Beta}(3, 9)$  をグラフで確認




Figure:  $\text{Beta}(3, 9)$  の確率密度関数 ( $q$  の事後分布) .  $q = 0.2$  は最尤推定値

# 直感的イメージ

- 最尤法： $q$  の推定値は 1 点 ( $q = 0.2$ ).  
→ 予測分布は確率モデルに推定値を代入してつくる
- ベイズ推測： $q$  の事後分布は  $\text{Beta}(3, 9)$ .  
→ 予測分布は確率モデルを事後分布で平均してつくる

確率モデルの平均？ → 具体的に計算してみよう

# 予測分布

行動  $y \in \{0, 1\}$  の予測分布は

$$p^*(y) = \int_0^1 \underbrace{p(y|q)}_{\text{確率モデル}} \underbrace{p(q|y^n)}_{\text{事後分布}} dq.$$

予測分布は、事後分布による**期待値**

期待値だから

$$E[X] = \int x f(x) dx$$

と形式的には同じ ( $x$  が確率モデル,  $f(x)$  が事後分布だと考えればよい).



$Y = 1$  となる予測確率  $p^*(y)$  は,

$$\begin{aligned} p^*(y) &= p^*(1) \\ &= \int_0^1 P(Y = 1) \cdot p(q|y^n) dq \\ &= \int_0^1 q \cdot p(q|y^n) dq \\ &= \frac{a + \sum y_i}{a + b + n} \end{aligned}$$

$a, b$  は事前分布（ベータ分布）のパラメータ

ベイズ推測の結果得た予測分布は，パラメータ  $q$  の事後分布の期待値  $(a + \sum y_i)/(a + b + n)$  をパラメータとするベルヌーイ分布と見なせる．つまり

$$Y_{n+1} \sim \text{Bernoulli} \left( \frac{a + \sum y_i}{a + b + n} \right)$$

データに基づいて具体的にパラメータの値を計算すると

$$\frac{a + \sum y_i}{a + b + n} = \frac{1 + 2}{1 + 1 + 10} = \frac{3}{12} = 0.25$$

より

$$Y_{n+1} \sim \text{Bernoulli}(0.25)$$

### 3 章まとめ

- ベイズ推測に必要な（主な）道具は，《仮の確率モデル》《パラメータの事前分布》《パラメータの事後分布》である
- パラメータの事後分布は確率モデルと事前分布から計算できる．ただし解析的に解けない場合がある
- 事後分布の解析的計算が可能な事前分布を，共役事前分布という
- 事後分布による確率モデルの平均がベイズ推測の予測分布である．事後分布を使って計算した予測分布により，真の分布を推測することをベイズ推測という

解析的：ここでは陽表的な関数として表せる，くらいの意味